Московский физико-технический институт
Физтех-школа прикладной математики и информатики

ВВЕДЕНИЕ В АНАЛИЗ ДАННЫХ

IV СЕМЕСТР

Лектор:

$h\nu$

Автор: *Киселев Николай*
Репозиторий на Github

весна 2025

Содержание

1 Задача линейной регрессии **2**
1.1 Прямой подход 2
1.2 Градиентный спуск (GD) 2
1.3 Стохастический градиентный спуск (SGD) 3

2 Линейные модели классификации **4**
2.1 Случай двух классов 4
2.2 Логистическая регрессия 4
2.3 Обучение логистической регресии 5
2.4 Многоклассовый случай 6

3 Связь экспоненциального и пуассоновского распределний **6**

4 Байесовские модели **7**
4.1 Гауссовские классификаторы 8
4.2 Наивный Байес 8

1 Задача линейной регрессии

1.1 Прямой подход

Будем рассматривать следующие модели:

$$\mathcal{M} = \{y : \mathbb{R}^d \to \mathbb{R} | y(x) = x^T\theta, \theta \in \mathbb{R}^d\}$$

Наша цель — получить наилучшую модель, то есть оценить θ.
Пусть $\hat{\theta}$ — оценка θ. Тогда $\hat{y}(x) = x^T\hat{\theta}$ — предсказание для x.
Пусть $x_1, \dots x_n$ — объекты, $Y_1, \dots Y_n$ — таргеты. Пусть $\hat{Y}_i = \hat{y}(x_i)$
Введем функционал ошибки:

$$\mathcal{L}(y, z) = (y - z)^2$$

И тогда получаем, что

$$F(\theta) = \sum_{i=1}^{n} \mathcal{L}(Y_i, \hat{Y}_i) = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^{n} \left(Y_i - x_i^T\hat{\theta}\right) = \|Y - X\hat{\theta}\|^2$$

Где

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, X = \begin{pmatrix} x_{11} & \dots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{n1} & \dots & x_{nd} \end{pmatrix}$$

Мы хотим минимизировать $F(\theta)$

Утверждение 1.1. *Если XX^T не вырождена, то $\hat{\theta} = (X^TX)^{-1}X^TY$*

Доказательство.

$$F(\theta) = \|Y - X\theta\|^2 = (Y - X\theta)^T(Y - X\theta) = Y^TY - 2Y^TX\theta + \theta^TX^TX\theta$$

Посчитаем градиент данной функции по θ:

$$\nabla F(\theta) = -2X^TY + 2X^TX\theta = 0$$

Домножим на $(X^TX)^{-1}$ слева:

$$\hat{\theta} = \underbrace{(X^TX)^{-1}X^T}_{\text{псевдообратная матрица}} Y$$

Т.к. функция $\|Y - X\theta\|^2$ квадратична, точка с нулевым градиентом является точкой минимума. □

1.2 Градиентный спуск (GD)

Пусть у нас есть задача $f(x) \to \min_x$.

Замечание. ∇f — направление наибольшего роста $f(x)$ в точке x.

Идея: будем идти в противоположную сторону. Пусть x_0 — начальное приближение. Будем действовать по следующему алгоритму: будем постепенно делать шаги, каждый новый шаг определяется формулой $x_{t+1} = x_t - \eta \nabla f$, где η — шаг метода.

Пример. Рассмотрим $f(x) = x^2 \Rightarrow \nabla f = 2x$. GD даст нам $x_{t+1} = x_t - 2\eta x_t$. При $\eta = 1$ мы получим $x_{t+1} = -x_t$.

Пример. Рассмотрим $f(x) = x^4 \Rightarrow \nabla f = 4x^3$. GD даст нам $x_{t+1} = x_t - 2\eta x_t$. При $\eta = 1$ мы получим $x_{t+1} = -4x_t$, т.е. наша последовательность не сходится.

Применим GD к задаче линейной регрессии: $F(\theta) = \|Y - X\theta\|^2 \to \min_\theta$

$$\nabla F(\theta) = -2X^T Y + 2X^T X\theta = 2X^T(X\theta - Y)$$

Шаг GD (занесем константу 2 в η):

$$\theta_{t+1} = \theta_t - \eta X^T(X\theta_t - Y) = \theta_t - \eta \sum_{i=1}^{n} x_i(x_i^T \theta_t - Y_i)$$

Что мы можем сказать про градиентный спуск?

+ Не надо обращать матрицу.

− Если n велико, то каждый шаг выполняется долго

Возникает еще одна идея: а что если считать градиент не для каждого из n элементов, а для некоторого количества из них. Таким образом, мы приходим к идее стохастического градиентого спуска.

1.3 Стохастический градиентный спуск (SGD)

Возьмем индексы $I = \underbrace{\{i_1, \dots i_k\}}_{\text{батч}} \sim U\{1, 2, \dots n\}$ (отвечающие равномерному распределению), где k — размер батча. Тогда шаг стохастического градиентого спуска будет определяться по формуле:

$$\theta_{t+1} = \theta_t - \eta \frac{n}{k} \sum_{i \in I} x_i(x_i^T \theta_t - Y_i)$$

Здесь множитель $\frac{n}{k}$ добавлен для нормировки: т.к. мы взяли k объектов из n, то полученный градиент будет приблизительно в $\frac{n}{k}$ меньше исходного. Рассмотрим данные операции в матричном виде:

Пусть X_I — матрица из строк матрицы X с индексами $i_1, \dots i_k$, Y_I — вектор из элементов вектора Y с индексами $i_1, \dots i_k$. Таким образом, шаг SGD будет иметь следующий вид:

$$\theta_{t+1} = \theta_t - \eta \frac{n}{k} X_I^T (X_I \theta_t - Y_I)$$

Итого, процедура имеет следующий вид:

1. Сгенерировать набор I
2. Вычислить $\theta_{t+1} = \dots$

2 Линейные модели классификации

2.1 Случай двух классов

Пусть $x_1, \dots x_n \in \mathbb{R}^d$ — признаки, $y_1, \dots y_n \in \{0, 1\}$ — признаки. Мы предполагаем, что:

$$y_i = y_*(x_i, \varepsilon_i)$$

Где ε_i — неизвестные случайные величины.

Пример. $y_i = I\{x_i^T \theta_* + \varepsilon_i > 0\}$, где θ_* — неизвестна.

Мы будем предсказывать $P(y_i = 1) = \mu(x_i)$.

Замечание. Заметим, что $y_i \sim Bern(\mu(x_i))$.

Таким образом, мы свели задачу к задаче нахождения $\mu : \mathbb{R}^d \to [0, 1]$.

2.2 Логистическая регрессия

Мы будем предполагать, что $\mu_\theta(x) = \sigma(\theta^T x)$, где $\sigma(x) = \frac{1}{1+e^{-x}}$ — догистическая сигмоида.

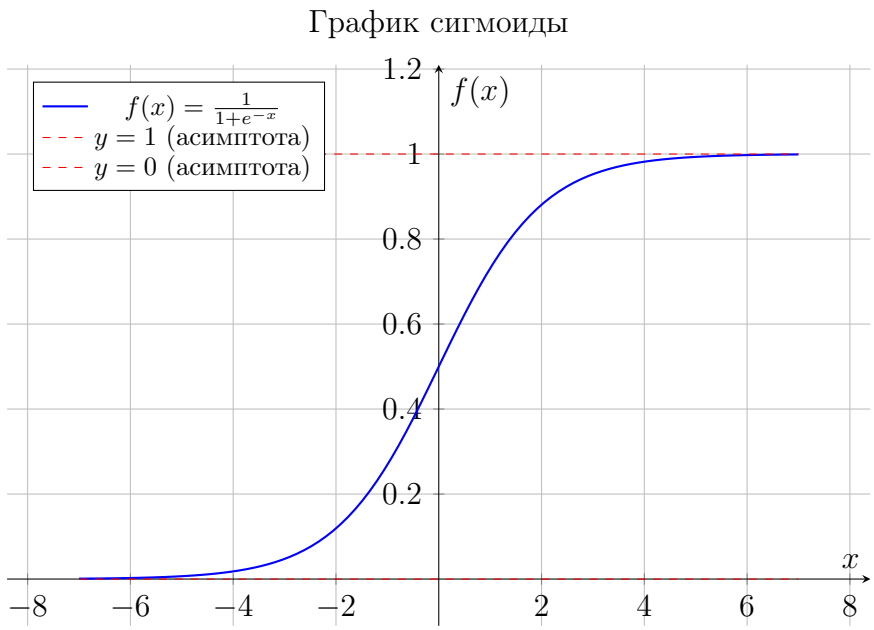

Рис. 1: Логистическая сигмоида

Замечание (Свойства $\sigma(z)$). 1. $\sigma(-z) = 1 - \sigma(z)$

2. $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

3. $\sigma^{-1}(s) = \ln \frac{s}{1-s}$ — логит-функция

Таким образом, если $s = P(y_i = 1)$, то $\frac{s}{1-s}$ — шанс, тогда $\ln \frac{s}{1-s}$ — логит-функция от шанса. Тогда наше предположение эквивалентно тому, что логит от шанса — линейная функция по x.

Соответственно, рассмотим множество моделей:

$$\mathcal{M} = \{\mu : \mathbb{R}^d \to [0,1] \ \mid \ \mu(x) = \sigma(\theta^T x), \theta \in \mathbb{R}^d\}$$

2.3 Обучение логистической регресии

Более подробно о кросс-энтропии и ее применении в теории кодирования — в презентации

Определение 2.1.

$$H(P,Q) = -\sum_{j=1}^{k} p_j \log_2 q_j$$

Для каждого объекта i рассмотрим кросс-энтропию $H(P_i, Q_i)$, где $Q_i = (1-\sigma(\theta^T x_i), \sigma(\theta^T x_i))$ — вероятность класса 0 и 1 соответственно. Это наше предполагаемое распределение для y_i. $P_i = (1-y_i, y_i)$ — наблюдаемое распределение y_i. Будем минимизировать сумму кросс-энтропий по всем объектам, т.е.

$$F(\theta) = \sum_{i=1}^{n} H(P_i, Q_i) = -\sum_{i=1}^{n} (1-y_i)\log_2(1-\sigma(\theta^T x_i)) + y_i \log_2 \sigma(\theta^T x_i) \to \min_{\theta \in \mathbb{R}^d}$$

Для минимизации, посчитаем градиент:

$$\nabla F(\theta) = -\sum_{i=1}^{n} \left((1-y_i)\frac{-\sigma(1-\sigma)}{1-\sigma} x_i + y_i \frac{\sigma(1-\sigma)}{\sigma} x_i \right)$$

$$\nabla F(\theta) = -\sum_{i=1}^{n} \left((1-y_i)\frac{-\sigma(1-\sigma)}{1-\sigma} x_i + y_i \frac{\sigma(1-\sigma)}{\sigma} x_i \right) = -\sum_{i=1}^{n} (y_i - \sigma(\theta^T x_i)) x_i = X^T(S(\theta) - Y)$$

Где $S(\theta) = \begin{pmatrix} \sigma(\theta^T x_1) \\ \vdots \\ \sigma(\theta^T x_n) \end{pmatrix}$

Таким образом, формула для градиентного спуска будет иметь следующий вид:

Градиентный спуск (GD):

$$\theta_{t+1} = \theta_t - \eta X^T (S(\theta) - Y)$$

Стохастический градиентный спуск (SGD):

$$\theta_{t+1} = \theta_t - \eta \frac{n}{k} X_I^T (S(\theta)_I - Y_I)$$

Где $I = \{i_1, \dots i_k\} \sim U\{1, \dots n\}$ — батчи отвечают равномерному распределению.

2.4 Многоклассовый случай

Замечание.

$$\sigma(z) = \frac{1}{1+e^{-z}} = \frac{e^{z/2}}{e^{-z/2}+e^{z/2}} = \frac{e^{z_1}}{e^{z_1}+e^{z_2}}$$

Таким образом, сигмоиду можно обобщить для k классов, положив:

$$\sigma(z_1, \dots z_k) = \left(\frac{e^{z_1}}{\sum_{i=1}^n e^{z_i}}, \dots \frac{e^{z_k}}{\sum_{i=1}^n e^{z_i}}\right)$$

В качестве $z_1, \dots z_k$ мы будем подставлять $z_i = x_i^T \theta_i$, как и в двуклассовом случае. Таким образом, наше предположение имеет вид:

$$P(y_i = j) = \frac{e^{z_j}}{\sum_{i=1}^n e^{z_i}}$$

3 Связь экспоненциального и пуассоновского распределний

Пусть у нас есть поток независимых событий, происходящих с одинаковой частотой. Предположим, что время между двумя последовательными событиями отвечает распределению $Exp(\lambda)$.

Пусть $\xi_1, \dots$ — н.о.р.с.в, отвечающие распределению $Exp(\lambda)$. Положим $S_0 = 0, S_n = \sum_{i=1}^n \xi_i, n \geqslant 1$. Теперь положим $X_t = \sup\{n \geqslant 0 | S_n \leqslant t\}$ — количество событий, которое произошло за время $[0, t]$. Таким образом, $X_t - X_s$ — количество событий, которое произошло за время $(s, t]$

Лемма 3.1 (б/д)**.** $S_n \sim Pois(nm\lambda)$

Теорема 3.1. $X_t \sim Pois(\lambda t)$

Доказательство. $\{X_t = m\} = \{S_m \leqslant t < S_{m+1}\}$. Заметим, что $S_{m+1} = S_m + \xi_{m+1}$. Получаем, что:

$$P(X_t = m) = \int_0^t P(\xi_{m+1} > t-u) f_{S_m}(u) du = \int_0^t e^{-\lambda(t-u)} \frac{\lambda^m u^{m-1}}{(m-1)!} e^{-\lambda u} du = e^{-\lambda t} \frac{(\lambda t)^m}{m!}$$

□

Теорема 3.2. $X_t - X_s \sim Pois(\lambda(t-s))$

Теорема 3.3. *Пусть полуинтервалы $(s_1, t_1], \dots (s_n, t_n]$ не пересекаются. Тогда случайные величины $X_{t_1} - X_{s_1}, \dots X_{t_n} - X_{s_n}$ независимы в совокупности*

Доказательство. Доказательство теоремы о независимости приращений (продолжение).

Рассмотрим два непересекающихся интервала, например $(0, t_1]$ и $(t_1, t_2]$ с $0 < t_1 < t_2$. Покажем, что X_{t_1} и $X_{t_2} - X_{t_1}$ независимы и имеют распределения Пуассона с параметрами λt_1 и $\lambda(t_2 - t_1)$ соответственно. Для этого вычислим совместную вероятность:

$$P(X_{t_1} = m, X_{t_2} - X_{t_1} = n) = P(S_m \leqslant t_1 < S_{m+1}, S_{m+n} \leqslant t_2 < S_{m+n+1}),$$

где $S_k = \sum_{i=1}^{k} \xi_i$, $\xi_i \sim \mathrm{Exp}(\lambda)$ независимы. Используя независимость S_m и $\xi_{m+1}, \ldots, \xi_{m+n+1}$, а также формулу полной вероятности, получаем:

$$P = \int_0^{t_1} f_{S_m}(s)\, P\big(\xi_{m+1} > t_1 - s,\, \xi_{m+1} + \cdots + \xi_{m+n} \leqslant t_2 - s,\, \xi_{m+1} + \cdots + \xi_{m+n+1} > t_2 - s\big)\, ds.$$

Сделаем замену $u = t_1 - s$ ($ds = -du$). Так как ξ_i — н.о.р.с.в, можно переиндексировать их внутри интеграла:

$$P = \int_0^{t_1} f_{S_m}(t_1 - u)\, P\big(\xi_1 > u,\, \xi_1 + \cdots + \xi_n \leqslant h + u,\, \xi_1 + \cdots + \xi_{n+1} > h + u\big)\, du,$$

где $h = t_2 - t_1$, а ξ_i – независимые экспоненциальные с параметром λ. В силу отсутствия памяти, условное распределение $\xi_1 - u$ при $\xi_1 > u$ снова является $\mathrm{Exp}(\lambda)$ и не зависит от $\xi_2, \ldots, \xi_{n+1}$. Поэтому внутренняя вероятность равна:

$$P(\xi_1 > u) \cdot P\big(\eta + \xi_2 + \cdots + \xi_n \leqslant h,\, \eta + \xi_2 + \cdots + \xi_{n+1} > h\big) = e^{-\lambda u} \cdot e^{-\lambda h} \frac{(\lambda h)^n}{n!},$$

где $\eta \sim \mathrm{Exp}(\lambda)$ независимо от $\xi_2, \ldots, \xi_{n+1}$. Подставляя это выражение, имеем:

$$P = e^{-\lambda h} \frac{(\lambda h)^n}{n!} \int_0^{t_1} f_{S_m}(t_1 - u)\, e^{-\lambda u}\, du.$$

Поскольку $f_{S_m}(t_1 - u) = \frac{\lambda^m (t_1 - u)^{m-1}}{(m-1)!} e^{-\lambda(t_1 - u)}$, то

$$f_{S_m}(t_1 - u) e^{-\lambda u} = \frac{\lambda^m (t_1 - u)^{m-1}}{(m-1)!} e^{-\lambda t_1}.$$

Интеграл $\int_0^{t_1} \frac{\lambda^m (t_1 - u)^{m-1}}{(m-1)!} e^{-\lambda t_1}\, du = e^{-\lambda t_1} \frac{(\lambda t_1)^m}{m!} = P(X_{t_1} = m)$. Следовательно,

$$P(X_{t_1} = m,\, X_{t_2} - X_{t_1} = n) = P(X_{t_1} = m) \cdot e^{-\lambda h} \frac{(\lambda h)^n}{n!} = P(X_{t_1} = m)\, P(X_{t_2} - X_{t_1} = n).$$

Таким образом, приращения на непересекающихся интервалах $(0,t_1]$ и $(t_1,t_2]$ независимы. Точно так же можно доказать независимость для n интервалов (доказательство будет полностью аналогично) □

4 Байесовские модели

Пусть $(X_1, Y_1), \ldots (X_n, Y_n)$ — обучающая выборка, где $Y \in \{1, \ldots K\}$. Вероятность того, что $Y = k$ при условии $X = x$. Формула Байеса (для непрерывного случая) дает следующий результат:

$$P(Y = k | X = x) = \frac{P(Y = k) p(x | Y = k)}{\sum_{i=1}^{K} P(Y = s) p(x | Y = s)}$$

Оценим $P(Y = k)$ и $p(x|Y = k)$ по данным. Положим $\widehat{\pi}_k = \frac{n_k}{n}$ — доля объектов класса k, $\widehat{p}_k(x)$ — оценка плотности объектов в классе k.

Тогда мы получаем оценку вероятности класса k для точки x:

$$\widehat{P}_k(x) = \frac{\widehat{\pi}_k \widehat{p}_k(x)}{\sum_{s=1}^{K} \widehat{\pi}_s \widehat{p}_s(x)}$$

И оценку класса:

$$\widehat{y}(x) = \operatorname{argmax}_k \widehat{P}_k(x) = \operatorname{argmax}_k \widehat{\pi}_k \widehat{p}(x) =$$

4.1 Гауссовские классификаторы

Предположим, что $p_k(x)$ — плотность $\mathcal{N}(a_k, \Sigma_k)$, т.е:

$$p_k(x) = \frac{1}{(2\pi)^{k/2}\sqrt{\det \Sigma_k}} e^{-\frac{1}{2}(x-a_k)^T \Sigma_k^{-1}(x-a_k)}$$

Пусть нам дана выборка X размера $n \times d$. Тогда (без доказательства) можно посчитать оценки:

$$\widehat{a}_k = \frac{1}{n_k} \sum_{i=1}^{n} X_i I\{Y_i = k\}$$

$$\widehat{\Sigma}_k = \frac{1}{n_k} \sum_{i=1}^{n} (X_i - \widehat{a}_k)^T (X_i - \widehat{a}_k) I\{Y_i = k\}$$

Разделяющая поверхность между классами k, l задается уравнением $\widehat{P}_k(x) = \widehat{P}_l(x)$. Положим $z(x) = \sum_{s=1}^{K} \widehat{\pi}_s \widehat{p}_s(x)$. Тогда мы можем посчитать:

$$\log \widehat{P}_k(x) = z(x) + \log \widehat{\pi}_k + \log \widehat{p}_k(x)$$

Сгруппируем все, что не зависит от x в выражении выше в константу c_k и c'_k:

$$\log \widehat{P}_k(x) = z(x) + c_k - \frac{1}{2}(x - \widehat{a}_k)^T \widehat{\Sigma}_k^{-1}(x - \widehat{a}_k) = z(x) - \frac{1}{2} x^T \widehat{\Sigma}_k^{-1} x + x^T \widehat{\Sigma}_k^{-1} \widehat{a}_k + c'_k$$

В итоге получаем, что:

$$\widehat{P}_k(x) = \widehat{P}_l(x) \Leftrightarrow \frac{1}{2} x^T \widehat{\Sigma}_k^{-1} x + x^T \widehat{\Sigma}_k^{-1} \widehat{a}_k + c'_k = \frac{1}{2} x^T \widehat{\Sigma}_l^{-1} x + x^T \widehat{\Sigma}_l^{-1} \widehat{a}_l + c'_l$$

Замечание. Разделяющая поверхность квадратична. Кроме того, если $\widehat{\Sigma}_1 = \cdots = \widehat{\Sigma}_k$, то разделяющие поверхности линейны.

4.2 Наивный Байес

Предположение: признаки в каждом классе независимы в совокупности.

В таком случае мы можем явно выразить плотность:

$$p(X|Y = k) = \prod_{j=1}^{d} p(X_j|Y = k)$$

Рассмотрим случай $X_j \in \{0, 1\}$. Тогда

$$p(X|Y=k) = \prod_{j=1}^{d} P(X_j = x_j|Y=k) = \prod_{j=1}^{d} \left\{ \begin{array}{c} p_{jk}, \text{ если } x_j = 1 \\ 1 - p_{jk}, \text{ если } x_j = 0 \end{array} \right\} = \prod_{j=1}^{d} p_{jk}^{x_j}(1-p_{jk})^{1-x_j}$$

Далее досаточно оценить p_{jk} по данным.