

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

ВВЕДЕНИЕ В АНАЛИЗ ДАННЫХ
IV СЕМЕСТР

Лектор:



Автор: *Киселев Николай*
Репозиторий на Github

весна 2025

Содержание

1	Задача линейной регрессии	2
1.1	Прямой подход	2
1.2	Градиентный спуск (GD)	2
1.3	Стохастический градиентный спуск (SGD)	3
2	Линейные модели классификации	4
2.1	Случай двух классов	4
2.2	Логистическая регрессия	4
2.3	Обучение логистической регрессии	5
2.4	Многоклассовый случай	6
3	Связь экспоненциального и пуассоновского распределений	6
4	Байесовские модели	7
4.1	Гауссовские классификаторы	8
4.2	Наивный Байес	8
5	Ложные корреляции	9
5.1	Случай вилки	9
5.2	Случай цепочки	9
5.3	Случай коллайдера	9
6	Введение в математическую статистику	10
6.1	Выборочное среднее	10
6.2	Свойства выборочного среднего	10
6.3	Стратификация	11

1 Задача линейной регрессии

1.1 Прямой подход

Будем рассматривать следующие модели:

$$\mathcal{M} = \{y : \mathbb{R}^d \rightarrow \mathbb{R} | y(x) = x^T \theta, \theta \in \mathbb{R}^d\}$$

Наша цель — получить наилучшую модель, то есть оценить θ .

Пусть $\hat{\theta}$ — оценка θ . Тогда $\hat{y}(x) = x^T \hat{\theta}$ — предсказание для x .

Пусть $x_1, \dots, x_n$ — объекты, $Y_1, \dots, Y_n$ — таргеты. Пусть $\hat{Y}_i = \hat{y}(x_i)$

Введем функционал ошибки:

$$\mathcal{L}(y, z) = (y - z)^2$$

И тогда получаем, что

$$F(\theta) = \sum_{i=1}^n \mathcal{L}(Y_i, \hat{Y}_i) = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - x_i^T \hat{\theta})^2 = \|Y - X\hat{\theta}\|^2$$

Где

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, X = \begin{pmatrix} x_{11} & \dots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{n1} & \dots & x_{nd} \end{pmatrix}$$

Мы хотим минимизировать $F(\theta)$

Утверждение 1.1. Если XX^T не вырождена, то $\hat{\theta} = (X^T X)^{-1} X^T Y$

Доказательство.

$$F(\theta) = \|Y - X\theta\|^2 = (Y - X\theta)^T (Y - X\theta) = Y^T Y - 2Y^T X\theta + \theta^T X^T X\theta$$

Посчитаем градиент данной функции по θ :

$$\nabla F(\theta) = -2X^T Y + 2X^T X\theta = 0$$

Домножим на $(X^T X)^{-1}$ слева:

$$\hat{\theta} = \underbrace{(X^T X)^{-1} X^T}_{\text{псевдообратная матрица}} Y$$

Т.к. функция $\|Y - X\theta\|^2$ квадратична, точка с нулевым градиентом является точкой минимума. $\square$

1.2 Градиентный спуск (GD)

Пусть у нас есть задача $f(x) \rightarrow \min_x$.

Замечание. ∇f — направление наибольшего роста $f(x)$ в точке x .

Идея: будем идти в противоположную сторону. Пусть x_0 — начальное приближение. Будем действовать по следующему алгоритму: будем постепенно делать шаги, каждый новый шаг определяется формулой $x_{t+1} = x_t - \eta \nabla f$, где η — шаг метода.

Пример. Рассмотрим $f(x) = x^2 \Rightarrow \nabla f = 2x$. GD даст нам $x_{t+1} = x_t - 2\eta x_t$. При $\eta = 1$ мы получим $x_{t+1} = -x_t$.

Пример. Рассмотрим $f(x) = x^4 \Rightarrow \nabla f = 4x^3$. GD даст нам $x_{t+1} = x_t - 2\eta x_t$. При $\eta = 1$ мы получим $x_{t+1} = -4x_t$, т.е. наша последовательность не сходится.

Применим GD к задаче линейной регрессии: $F(\theta) = \|Y - X\theta\|^2 \rightarrow \min_{\theta}$

$$\nabla F(\theta) = -2X^T Y + 2X^T X \theta = 2X^T (X\theta - Y)$$

Шаг GD (занесем константу 2 в η):

$$\theta_{t+1} = \theta_t - \eta X^T (X\theta_t - Y) = \theta_t - \eta \sum_{i=1}^n x_i (x_i^T \theta_t - Y_i)$$

Что мы можем сказать про градиентный спуск?

- + Не надо обращать матрицу.
- Если n велико, то каждый шаг выполняется долго

Возникает еще одна идея: а что если считать градиент не для каждого из n элементов, а для некоторого количества из них. Таким образом, мы приходим к идее стохастического градиентного спуска.

1.3 Стохастический градиентный спуск (SGD)

Возьмем индексы $I = \underbrace{\{i_1, \dots, i_k\}}_{\text{батч}} \sim U\{1, 2, \dots, n\}$ (отвечающие равномерному распределению), где k — размер батча. Тогда шаг стохастического градиентного спуска будет определяться по формуле:

$$\theta_{t+1} = \theta_t - \eta \frac{n}{k} \sum_{i \in I} x_i (x_i^T \theta_t - Y_i)$$

Здесь множитель $\frac{n}{k}$ добавлен для нормировки: т.к. мы взяли k объектов из n , то полученный градиент будет приблизительно в $\frac{n}{k}$ меньше исходного. Рассмотрим данные операции в матричном виде:

Пусть X_I — матрица из строк матрицы X с индексами $i_1, \dots, i_k$, Y_I — вектор из элементов вектора Y с индексами $i_1, \dots, i_k$. Таким образом, шаг SGD будет иметь следующий вид:

$$\theta_{t+1} = \theta_t - \eta \frac{n}{k} X_I^T (X_I \theta_t - Y_I)$$

Итого, процедура имеет следующий вид:

1. Сгенерировать набор I
2. Вычислить $\theta_{t+1} = \dots$

2 Линейные модели классификации

2.1 Случай двух классов

Пусть $x_1, \dots, x_n \in \mathbb{R}^d$ — признаки, $y_1, \dots, y_n \in \{0, 1\}$ — признаки. Мы предполагаем, что:

$$y_i = y_*(x_i, \varepsilon_i)$$

Где ε_i — неизвестные случайные величины.

Пример. $y_i = I\{x_i^T \theta_* + \varepsilon_i > 0\}$, где θ_* — неизвестна.

Мы будем предсказывать $P(y_i = 1) = \mu(x_i)$.

Замечание. Заметим, что $y_i \sim \text{Bern}(\mu(x_i))$.

Таким образом, мы свели задачу к задаче нахождения $\mu : \mathbb{R}^d \rightarrow [0, 1]$.

2.2 Логистическая регрессия

Мы будем предполагать, что $\mu_\theta(x) = \sigma(\theta^T x)$, где $\sigma(x) = \frac{1}{1+e^{-x}}$ — логистическая сигмоида.




Рис. 1: Логистическая сигмоида

Замечание (Свойства $\sigma(z)$). 1. $\sigma(-z) = 1 - \sigma(z)$

2. $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

3. $\sigma^{-1}(s) = \ln \frac{s}{1-s}$ — логит-функция

Таким образом, если $s = P(y_i = 1)$, то $\frac{s}{1-s}$ — шанс, тогда $\ln \frac{s}{1-s}$ — логит-функция от шанса. Тогда наше предположение эквивалентно тому, что логит от шанса — линейная функция по x .

Соответственно, рассмотрим множество моделей:

$$\mathcal{M} = \{\mu : \mathbb{R}^d \rightarrow [0, 1] \mid \mu(x) = \sigma(\theta^T x), \theta \in \mathbb{R}^d\}$$

2.3 Обучение логистической регрессии

Более подробно о кросс-энтропии и ее применении в теории кодирования — в [презентации](#)

Определение 2.1.

$$H(P, Q) = - \sum_{j=1}^k p_j \log_2 q_j$$

Для каждого объекта i рассмотрим кросс-энтропию $H(P_i, Q_i)$, где $Q_i = (1 - \sigma(\theta^T x_i), \sigma(\theta^T x_i))$ — вероятность класса 0 и 1 соответственно. Это наше предполагаемое распределение для y_i . $P_i = (1 - y_i, y_i)$ — наблюдаемое распределение y_i . Будем минимизировать сумму кросс-энтропий по всем объектам, т.е.

$$F(\theta) = \sum_{i=1}^n H(P_i, Q_i) = - \sum_{i=1}^n (1 - y_i) \log_2 (1 - \sigma(\theta^T x_i)) + y_i \log_2 \sigma(\theta^T x_i) \rightarrow \min_{\theta \in \mathbb{R}^d}$$

Для минимизации, посчитаем градиент:

$$\nabla F(\theta) = - \sum_{i=1}^n \left((1 - y_i) \frac{-\sigma(1 - \sigma)}{1 - \sigma} x_i + y_i \frac{\sigma(1 - \sigma)}{\sigma} x_i \right)$$

$$\nabla F(\theta) = - \sum_{i=1}^n \left((1 - y_i) \frac{-\sigma(1 - \sigma)}{1 - \sigma} x_i + y_i \frac{\sigma(1 - \sigma)}{\sigma} x_i \right) = - \sum_{i=1}^n (y_i - \sigma(\theta^T x_i)) x_i = X^T (S(\theta) - Y)$$

$$\text{Где } S(\theta) = \begin{pmatrix} \sigma(\theta^T x_1) \\ \vdots \\ \sigma(\theta^T x_n) \end{pmatrix}$$

Таким образом, формула для градиентного спуска будет иметь следующий вид:

Градиентный спуск (GD):

$$\theta_{t+1} = \theta_t - \eta X^T (S(\theta) - Y)$$

Стохастический градиентный спуск (SGD):

$$\theta_{t+1} = \theta_t - \eta \frac{n}{k} X_I^T (S(\theta)_I - Y_I)$$

Где $I = \{i_1, \dots, i_k\} \sim U\{1, \dots, n\}$ — батчи отвечают равномерному распределению.

2.4 Многоклассовый случай

Замечание.

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^{z/2}}{e^{-z/2} + e^{z/2}} = \frac{e^{z_1}}{e^{z_1} + e^{z_2}}$$

Таким образом, сигмоиду можно обобщить для k классов, положив:

$$\sigma(z_1, \dots, z_k) = \left(\frac{e^{z_1}}{\sum_{i=1}^n e^{z_i}}, \dots, \frac{e^{z_k}}{\sum_{i=1}^n e^{z_i}} \right)$$

В качестве $z_1, \dots, z_k$ мы будем подставлять $z_i = x_i^T \theta_i$, как и в двухклассовом случае. Таким образом, наше предположение имеет вид:

$$P(y_i = j) = \frac{e^{z_j}}{\sum_{i=1}^n e^{z_i}}$$

3 Связь экспоненциального и пуассоновского распределений

Пусть у нас есть поток независимых событий, происходящих с одинаковой частотой. Предположим, что время между двумя последовательными событиями отвечает распределению $Exp(\lambda)$.

Пусть $\xi_1, \dots$ — н.о.р.с.в, отвечающие распределению $Exp(\lambda)$. Положим $S_0 = 0, S_n = \sum_{i=1}^n \xi_i, n \geq 1$. Теперь положим $X_t = \sup\{n \geq 0 | S_n \leq t\}$ — количество событий, которое произошло за время $[0, t]$. Таким образом, $X_t - X_s$ — количество событий, которое произошло за время $(s, t]$

Лемма 3.1 (б/д). $S_n \sim Pois(nm\lambda)$

Теорема 3.1. $X_t \sim Pois(\lambda t)$

Доказательство. $\{X_t = m\} = \{S_m \leq t < S_{m+1}\}$. Заметим, что $S_{m+1} = S_m + \xi_{m+1}$. Получаем, что:

$$P(X_t = m) = \int_0^t P(\xi_{m+1} > t - u) f_{S_m}(u) du = \int_0^t e^{-\lambda(t-u)} \frac{\lambda^m u^{m-1}}{(m-1)!} e^{-\lambda u} du = e^{-\lambda t} \frac{(\lambda t)^m}{m!}$$

□

Теорема 3.2. $X_t - X_s \sim Pois(\lambda(t-s))$

Теорема 3.3. Пусть полуинтервалы $(s_1, t_1], \dots, (s_n, t_n]$ не пересекаются. Тогда случайные величины $X_{t_1} - X_{s_1}, \dots, X_{t_n} - X_{s_n}$ независимы в совокупности

Доказательство. Доказательство теоремы о независимости приращений (продолжение).

Рассмотрим два непересекающихся интервала, например $(0, t_1]$ и $(t_1, t_2]$ с $0 < t_1 < t_2$. Покажем, что X_{t_1} и $X_{t_2} - X_{t_1}$ независимы и имеют распределения Пуассона с параметрами λt_1 и $\lambda(t_2 - t_1)$ соответственно. Для этого вычислим совместную вероятность:

$$P(X_{t_1} = m, X_{t_2} - X_{t_1} = n) = P(S_m \leq t_1 < S_{m+1}, S_{m+n} \leq t_2 < S_{m+n+1}),$$

где $S_k = \sum_{i=1}^k \xi_i$, $\xi_i \sim \text{Exp}(\lambda)$ независимы. Используя независимость S_m и $\xi_{m+1}, \dots, \xi_{m+n+1}$, а также формулу полной вероятности, получаем:

$$P = \int_0^{t_1} f_{S_m}(s) P(\xi_{m+1} > t_1 - s, \xi_{m+1} + \dots + \xi_{m+n} \leq t_2 - s, \xi_{m+1} + \dots + \xi_{m+n+1} > t_2 - s) ds.$$

Сделаем замену $u = t_1 - s$ ($ds = -du$). Так как ξ_i — н.о.р.с.в, можно переиндексировать их внутри интеграла:

$$P = \int_0^{t_1} f_{S_m}(t_1 - u) P(\xi_1 > u, \xi_1 + \dots + \xi_n \leq h + u, \xi_1 + \dots + \xi_{n+1} > h + u) du,$$

где $h = t_2 - t_1$, а ξ_i — независимые экспоненциальные с параметром λ . В силу отсутствия памяти, условное распределение $\xi_1 - u$ при $\xi_1 > u$ снова является $\text{Exp}(\lambda)$ и не зависит от $\xi_2, \dots, \xi_{n+1}$. Поэтому внутренняя вероятность равна:

$$P(\xi_1 > u) \cdot P(\eta + \xi_2 + \dots + \xi_n \leq h, \eta + \xi_2 + \dots + \xi_{n+1} > h) = e^{-\lambda u} \cdot e^{-\lambda h} \frac{(\lambda h)^n}{n!},$$

где $\eta \sim \text{Exp}(\lambda)$ независимо от $\xi_2, \dots, \xi_{n+1}$. Подставляя это выражение, имеем:

$$P = e^{-\lambda h} \frac{(\lambda h)^n}{n!} \int_0^{t_1} f_{S_m}(t_1 - u) e^{-\lambda u} du.$$

Поскольку $f_{S_m}(t_1 - u) = \frac{\lambda^m (t_1 - u)^{m-1}}{(m-1)!} e^{-\lambda(t_1 - u)}$, то

$$f_{S_m}(t_1 - u) e^{-\lambda u} = \frac{\lambda^m (t_1 - u)^{m-1}}{(m-1)!} e^{-\lambda t_1}.$$

Интеграл $\int_0^{t_1} \frac{\lambda^m (t_1 - u)^{m-1}}{(m-1)!} e^{-\lambda t_1} du = e^{-\lambda t_1} \frac{(\lambda t_1)^m}{m!} = P(X_{t_1} = m)$. Следовательно,

$$P(X_{t_1} = m, X_{t_2} - X_{t_1} = n) = P(X_{t_1} = m) \cdot e^{-\lambda h} \frac{(\lambda h)^n}{n!} = P(X_{t_1} = m) P(X_{t_2} - X_{t_1} = n).$$

Таким образом, приращения на непересекающихся интервалах $(0, t_1]$ и $(t_1, t_2]$ независимы. Точно так же можно доказать независимость для n интервалов (доказательство будет полностью аналогично) $\square$

4 Байесовские модели

Пусть $(X_1, Y_1), \dots, (X_n, Y_n)$ — обучающая выборка, где $Y \in \{1, \dots, K\}$. Вероятность того, что $Y = k$ при условии $X = x$. Формула Байеса (для непрерывного случая) дает следующий результат:

$$P(Y = k | X = x) = \frac{P(Y = k)p(x|Y = k)}{\sum_{i=1}^K P(Y = i)p(x|Y = i)}$$

Оценим $P(Y = k)$ и $p(x|Y = k)$ по данным. Положим $\hat{\pi}_k = \frac{n_k}{n}$ — доля объектов класса k , $\hat{p}_k(x)$ — оценка плотности объектов в классе k .

Тогда мы получаем оценку вероятности класса k для точки x :

$$\hat{P}_k(x) = \frac{\hat{\pi}_k \hat{p}_k(x)}{\sum_{s=1}^K \hat{\pi}_s \hat{p}_s(x)}$$

И оценку класса:

$$\hat{y}(x) = \operatorname{argmax}_k \hat{P}_k(x) = \operatorname{argmax}_k \hat{\pi}_k \hat{p}_k(x) =$$

4.1 Гауссовские классификаторы

Предположим, что $p_k(x)$ — плотность $\mathcal{N}(a_k, \Sigma_k)$, т.е:

$$p_k(x) = \frac{1}{(2\pi)^{k/2} \sqrt{\det \Sigma_k}} e^{-\frac{1}{2}(x-a_k)^T \Sigma_k^{-1} (x-a_k)}$$

Пусть нам дана выборка X размера $n \times d$. Тогда (без доказательства) можно посчитать оценки:

$$\hat{a}_k = \frac{1}{n_k} \sum_{i=1}^n X_i I\{Y_i = k\}$$

$$\hat{\Sigma}_k = \frac{1}{n_k} \sum_{i=1}^n (X_i - \hat{a}_k)^T (X_i - \hat{a}_k) I\{Y_i = k\}$$

Разделяющая поверхность между классами k, l задается уравнением $\hat{P}_k(x) = \hat{P}_l(x)$. Положим $z(x) = \sum_{s=1}^K \hat{\pi}_s \hat{p}_s(x)$. Тогда мы можем посчитать:

$$\log \hat{P}_k(x) = z(x) + \log \hat{\pi}_k + \log \hat{p}_k(x)$$

Сгруппируем все, что не зависит от x в выражении выше в константу c_k и c'_k :

$$\log \hat{P}_k(x) = z(x) + c_k - \frac{1}{2}(x - \hat{a}_k)^T \hat{\Sigma}_k^{-1} (x - \hat{a}_k) = z(x) - \frac{1}{2}x^T \hat{\Sigma}_k^{-1} x + x^T \hat{\Sigma}_k^{-1} \hat{a}_k + c'_k$$

В итоге получаем, что:

$$\hat{P}_k(x) = \hat{P}_l(x) \Leftrightarrow \frac{1}{2}x^T \hat{\Sigma}_k^{-1} x + x^T \hat{\Sigma}_k^{-1} \hat{a}_k + c'_k = \frac{1}{2}x^T \hat{\Sigma}_l^{-1} x + x^T \hat{\Sigma}_l^{-1} \hat{a}_l + c'_l$$

Замечание. Разделяющая поверхность квадратична. Кроме того, если $\hat{\Sigma}_1 = \dots = \hat{\Sigma}_k$, то разделяющие поверхности линейны.

4.2 Наивный Байес

Предположение: признаки в каждом классе независимы в совокупности.

В таком случае мы можем явно выразить плотность:

$$p(X|Y = k) = \prod_{j=1}^d p(X_j|Y = k)$$

Рассмотрим случай $X_j \in \{0, 1\}$. Тогда

$$p(X|Y = k) = \prod_{j=1}^d P(X_j = x_j|Y = k) = \prod_{j=1}^d \left\{ \begin{array}{l} p_{jk}, \text{ если } x_j = 1 \\ 1 - p_{jk}, \text{ если } x_j = 0 \end{array} \right\} = \prod_{j=1}^d p_{jk}^{x_j} (1 - p_{jk})^{1-x_j}$$

Далее досаточно оценить p_{jk} по данным.

5 Ложные корреляции

5.1 Случай вилки

Пусть x зависит от z и y зависит от z . Тогда:

$$p(x, y, z) = p(z)p(x|z)p(y|z)$$

Пример (x, y могут быть зависимы). Пусть $z = \varepsilon_1, x = \alpha\varepsilon_1 + \varepsilon_2, y = \beta\varepsilon_1 + \varepsilon_3$. Тогда:

$$\text{cov}(x, y) = \text{cov}(\alpha\varepsilon_1 + \varepsilon_2, \beta\varepsilon_1 + \varepsilon_3) = \alpha\beta \mathbf{D} \varepsilon_1$$

При $\alpha, \beta \neq 0$ получили ненулевую ковариацию

Теперь покажем в общем случае, что x и y независимы при условии z .

$$p(x, y|z) = \frac{p(x, y, z)}{p(z)} = p(x|z)p(y|z)$$

5.2 Случай цепочки

Пусть z зависит от x и y зависит от z . Тогда:

$$p(x, y, z) = p(x)p(z|x)p(y|z)$$

Пример (x, y могут быть зависимы). Пусть $x = \varepsilon_1, z = \alpha x + \varepsilon_2, y = \beta z + \varepsilon_3$. Тогда:

$$\text{cov}(x, y) = \text{cov}(\varepsilon_1, \beta(\alpha\varepsilon_1 + \varepsilon_2) + \varepsilon_3) = \alpha\beta \mathbf{D} \varepsilon_1$$

При $\alpha, \beta \neq 0$ получили ненулевую ковариацию

Теперь покажем в общем случае, что x и y независимы при условии z .

$$p(x, y|z) = \frac{p(x, y, z)}{p(z)} = \frac{p(x)p(z|x)p(y|z)}{p(x)} = \frac{p(x)p(z|x)}{p(x)}p(y|z) = \frac{p(x, z)}{p(x)}p(y|z) = p(x|z)p(y|z)$$

5.3 Случай коллайдера

Пусть z зависит от x и z зависит от y . Тогда:

$$p(x, y, z) = p(x)p(y)p(z|x, y)$$

Покажем, что x, y независимы:

$$p(x, y) = \int p(x, y, z) dz = p(x)p(y) \int p(z|x, y) dz = p(x)p(y)$$

Замечание. Заметим, что случаи цепочки и вилки неотличимы для нейросетей. В реальном мире отличать эти цепочки могут владение знаниями в конкретной сфере знаний.

Вывод: думайте мозгом!

6 Введение в математическую статистику

6.1 Выборочное среднее

Пусть $X_1, \dots, X_n$ — выборка (набор н.о.р.с.в.) с конечной дисперсией. Тогда $\mathbb{E}X_1$ называют теоретическим средним, а $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ — выборочным средним.

Пример. X_i — выручка с объекта i . Тогда $\bar{X}$ — средняя выручка.

Пример. X_i — ошибка модели на объекте i . Тогда $\bar{X}$ — средняя ошибка.

6.2 Свойства выборочного среднего

Посчитаем матожидание выборочного среднего

$$\mathbb{E}\bar{X} = \mathbb{E} \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mathbb{E}X_1$$

Следствие. Выборочное среднее — несмещенная оценка $\mathbb{E}X_1$.

Также для выборочного среднего выполняется УЗБЧ:

Теорема 6.1 (УЗБЧ). $\bar{X} \xrightarrow{n.n.} \mathbb{E}X_1$ при $n \rightarrow \infty$.

Следствие. Выборочное среднее — сильно состоятельная оценка (т.е. в пределе сходится к $\mathbb{E}X_1$).

Теперь посчитаем дисперсию выборочного среднего:

$$D\bar{X} = D \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n^2} \sum_{i=1}^n D X_i = \frac{1}{n} D X_1$$

Запишем центральную предельную теорему для $\bar{X}$:

$$\frac{\sum_{i=1}^n X_i - n\mathbb{E}X_1}{\sqrt{n D X_1}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Преобразуем:

$$\frac{\frac{1}{n} \sum_{i=1}^n X_i - \mathbb{E}X_1}{\sqrt{\frac{D X_1}{n}}} \xrightarrow{d} \mathcal{N}(0, 1)$$

$$\frac{\bar{X} - \mathbb{E}X_1}{\sqrt{\mathbb{D}\bar{X}}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Известно, что с вероятностью $\approx 95\%$ выполнено (из свойств нормального распределения):

$$\begin{aligned} -2 &\leq \frac{\bar{X} - \mathbb{E}X_1}{\sqrt{\mathbb{D}\bar{X}}} \leq 2 \\ -2\sqrt{\mathbb{D}\bar{X}} &\leq \bar{X} - \mathbb{E}X_1 \leq 2\sqrt{\mathbb{D}\bar{X}} \end{aligned}$$

$$\bar{X} - 2\sqrt{\frac{\mathbb{D}X_1}{n}} \leq \mathbb{E}X_1 \leq \bar{X} + 2\sqrt{\frac{\mathbb{D}X_1}{n}}$$

Таким образом, чтобы оценить $\mathbb{E}X_1$, нам нужно знать $\mathbb{D}X_1$. Как ее оценить? Положим:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \overline{X^2} - \bar{X}^2$$

Возникает вопрос: можно ли сказать, что $S^2 \xrightarrow{\text{п.н.}} \mathbb{D}X_1$? Рассмотрим вектор $\begin{pmatrix} \overline{X^2} \\ \bar{X} \end{pmatrix}$ — сходится почти наверное к $\begin{pmatrix} \mathbb{E}X_1^2 \\ \mathbb{E}X_1 \end{pmatrix}$. Заметим, что по УЗБЧ т.к. $\mathbb{D}X_1^2 < +\infty$. Возьмем $f(x, y) = x - y^2$. Тогда $f(\overline{X^2}, \bar{X}) = S^2 \xrightarrow{\text{п.н.}} f(\mathbb{E}X_1^2, \mathbb{E}X_1) = \mathbb{D}X_1$.

Последнее стремление выполняется в силу теоремы о наследовании сходимости:

Теорема 6.2 (О наследовании сходимости). *Если $\xi_n \xrightarrow{\text{п.н.}} \xi$ и f непрерывна на B , таком, что $P(\xi \in B) = 1$. Тогда $f(\xi_n) \xrightarrow{\text{п.н.}} f(\xi)$.*

Поскольку S^2 — хорошая оценка дисперсии, то подставим ее в качестве $\mathbb{D}X_1$ и получим:

$$\bar{X} - 2\frac{S}{\sqrt{n}} \leq \mathbb{E}X_1 \leq \bar{X} + 2\frac{S}{\sqrt{n}}$$

6.3 Стратификация

Пусть данные делятся на n страт. Положим:

1. μ_j — среднее в страте j
2. σ_j^2 — дисперсия в страте j
3. w_j — доля страты j (известная нам)

Будем брать выборку стратифицированно по стратам, т.е.

1. $n_j = nw_j$ — количество элементов в выборке в страте j .
2. $\bar{X}_j$ — среднее по выборке в страте j

Посчитаем матожидание:

$$\mathbb{E}(\bar{X} | n_j = nw_j \forall j) = \mathbb{E}\left(\frac{1}{n} \sum_{j=1}^k n_j \bar{X}_j | n_j = nw_j \forall j\right) = \frac{1}{n} \sum_{j=1}^k nw_j \mathbb{E}\bar{X}_j = \sum_{j=1}^k w_j \mu_j = \mu$$

То есть получили несмещенную оценку среднего. Теперь посчитаем дисперсию:

$$\begin{aligned} D(\bar{X}|n_j = nw_j \forall j) &= D\left(\frac{1}{n} \sum_{j=1}^k n_j \bar{X}_j | n_j = nw_j \forall j\right) = \\ &= \frac{1}{n^2} \sum_{j=1}^k n^2 w_j^2 D(\bar{X}_j | n_j = nw_j) = \sum_{j=1}^k w_j^2 \frac{\sigma_j^2}{nw_j} = \frac{1}{n} \sum_{j=1}^k w_j \sigma_j^2 \end{aligned}$$

Вспомним, что раньше мы получали дисперсию $\frac{\sigma^2}{n}$. Сравним эти две оценки. Дисперсия при случайном семплировании:

$$\begin{aligned} D X_i &= \mathbb{E} D(X_i | Z_i) + D \mathbb{E}(X_i | Z_i) = \mathbb{E} \sum_{j=1}^k \sigma_j^2 I\{Z_i = j\} + D \sum_{j=1}^k \mu_j I\{Z_i = j\} = \\ &= \sum_{j=1}^k \sigma_j^2 \mathbb{E} I\{Z_i = j\} + \mathbb{E} \left(\sum_{j=1}^k \mu_j I\{Z_i = j\} \right)^2 - \left(\mathbb{E} \sum_{j=1}^k \mu_j I\{Z_i = j\} \right)^2 = \\ &= \sum_{j=1}^k w_j \sigma_j^2 + \sum_{j=1}^k \underbrace{\mu_j^2 \mathbb{E} I\{Z_i = j\}}_{w_j} - \mu^2 \end{aligned}$$

Теперь найдем знак $\sum_{j=1}^k \underbrace{\mu_j^2 \mathbb{E} I\{Z_i = j\}}_{w_j} - \mu^2$:

$$\begin{aligned} \sum_{j=1}^k \underbrace{\mu_j^2 \mathbb{E} I\{Z_i = j\}}_{w_j} - \mu^2 &= \sum_{j=1}^k \underbrace{\mu_j^2 \mathbb{E} I\{Z_i = j\}}_{w_j} - 2\mu^2 + \mu^2 = \\ &= \sum_{j=1}^k \underbrace{\mu_j^2 \mathbb{E} I\{Z_i = j\}}_{w_j} - 2\mu \sum_{j=1}^k w_j \mu_j + \mu^2 \sum_{j=1}^k w_j = \sum_{j=1}^k (\mu_j - \mu)^2 \end{aligned}$$

Таким образом:

$$D \bar{X} = \frac{1}{n} D X_i = \frac{1}{n} \sum_{j=1}^k w_j \sigma_j^2 + \frac{1}{n} \sum_{j=1}^k (\mu_j - \mu)^2$$

Таким образом, стратификация уменьшает дисперсию, причем чем сильнее в классах отличаются матожидания, тем меньше будет дисперсия.